Evaluación de Arquitecturas de Redes Neuronales Convolucionales con Bloques Residuales para la Clasificación Multiclase de Texturas Tisulares en Cáncer Colorrectal

Joss Erick Bendezu Arana
Facultad de Ingeniería de Sistemas
Universidad Nacional del Centro del Perú
Huancayo, Perú
e_2024200180K@uncp.edu.pe

Polmar Yacid Briceño Carrión
Facultad de Ingeniería de Sistemas
Universidad Nacional del Centro del Perú
Huancayo, Perú
e_2024200182M@uncp.edu.pe

Jhordan Aldair Morales Huaman
Facultad de Ingeniería de Sistemas
Universidad Nacional del Centro del Perú
Huancayo, Perú
e_2024200194L@uncp.edu.pe

Antony Rodrigo Morales Valverde
Facultad de Ingeniería de Sistemas
Universidad Nacional del Centro del Perú
Huancayo, Perú
e_2024200195M@uncp.edu.pe

***Resumen*—La caracterización automática de tejidos en imágenes histológicas de cáncer colorrectal podría aliviar parte de la carga de inspección visual que hoy recae sobre el patólogo. En este trabajo comparamos tres redes neuronales convolucionales entrenadas desde cero sobre el conjunto Kather-texture-2016, compuesto por 5000 parches RGB de 150×150 píxeles distribuidos en ocho clases balanceadas: un modelo base de tres bloques convolucionales, una variante con bloques residuales y una arquitectura optimizada que integra el aumento de datos dentro del grafo, regularización L2 y Dropout escalonado. Los tres modelos se entrenaron bajo una misma configuración y se eligieron exclusivamente con el Macro F1 de validación, sujeto a límites de tamaño (< 50 MB) y de latencia en CPU (< 100 ms por imagen), sin consultar el conjunto de prueba. La CNN Optimizada, finalista del proceso, alcanzó en prueba una exactitud de 0.9227, un Macro F1 de 0.9227 (IC 95 % por bootstrap: 0.9015–0.9405) y un Macro AUC de 0.9948, con 2.46 M de parámetros y 74.0 ms por imagen en la CPU de Colab. La variante residual sin regularización adicional logró el mayor desempeño bruto (Macro F1 de 0.9301), pero superó el presupuesto de latencia. Los errores se concentran en las clases Complejo, Estroma y Linfocitos. Como la partición es estratificada por parche y no por paciente, los resultados no deben leerse como evidencia de validez diagnóstica.**

***Palabras clave*—redes neuronales convolucionales, bloques residuales, histopatología, cáncer colorrectal, clasificación multiclase, Kather-texture-2016**

I. Introducción

El examen microscópico de láminas teñidas con hematoxilina y eosina sigue siendo una pieza central en el diagnóstico del cáncer colorrectal. Se trata, sin embargo, de un trabajo lento, que exige experiencia y que admite cierta variabilidad entre observadores. Por eso, desde hace varios años se explora el uso de aprendizaje profundo para reconocer de forma automática los distintos tipos de tejido presentes en una lámina, de modo que el especialista pueda concentrarse en las regiones realmente relevantes [2], [3].

Las redes neuronales convolucionales (CNN) son hoy la opción natural para esta tarea, porque aprenden jerarquías de patrones visuales a partir de los propios píxeles. A medida que se profundizan, no obstante, se vuelven más difíciles de optimizar. Las conexiones residuales introducidas por He et al. [4] atenúan ese problema al permitir que cada bloque aprenda una corrección sobre su entrada, y han sido adoptadas ampliamente en visión por computador. Aun así, en problemas de tamaño moderado como el que aquí se aborda, no es evidente cuánto aportan frente a una red convolucional sencilla, ni a qué costo en parámetros, memoria y tiempo de inferencia.

Buena parte de la literatura reporta únicamente el mejor valor de exactitud alcanzado. Con menos frecuencia se explicita cómo se eligió el modelo final, si hubo restricciones de despliegue o si el conjunto de prueba se mantuvo realmente aislado de las decisiones de diseño. Este trabajo intenta cubrir esa brecha. Nuestras contribuciones son las siguientes:

- Un estudio comparativo de tres CNN (un modelo base y dos variantes con bloques residuales) entrenadas bajo condiciones idénticas sobre Kather-texture-2016.
- Un protocolo de selección declarado de antemano: el modelo se escoge por Macro F1 de validación dentro de límites de tamaño y de latencia, y el conjunto de prueba se consulta solo después de fijar la decisión.
- Un análisis de errores, de confianza y de calibración del modelo finalista, acompañado de una discusión explícita de las limitaciones de la partición por parche.

El resto del documento se organiza así: la Sección II resume los antecedentes, la Sección III describe los datos, las arquitecturas y el protocolo experimental, la Sección IV presenta los resultados, la Sección V los discute y la Sección VI concluye.

II. Antecedentes

El conjunto empleado fue presentado por Kather et al. [1], quienes clasificaron ocho tipos de tejido con descriptores de textura diseñados a mano y clasificadores tradicionales, con una exactitud cercana al 87 % en validación cruzada. Esa cifra no es directamente comparable con la nuestra, pues difieren el esquema de partición y el tipo de modelo, pero sirve como referencia histórica del punto de partida.

Con el auge del aprendizaje profundo, el reconocimiento de patrones en histología pasó de depender de descriptores artesanales a aprender representaciones directamente de los píxeles [2], [3]. En paralelo, se consolidó un conjunto de técnicas que estabilizan y regularizan el entrenamiento: normalización por lotes [5], Dropout [6] (incluida su variante espacial), suavizado de etiquetas, agrupamiento global promedio y aumento de datos. Nuestras tres arquitecturas combinan estos ingredientes en distintas proporciones, lo que permite aislar el efecto de las conexiones residuales y de la regularización adicional.

III. Materiales y métodos

III-A. Conjunto de datos y auditoría de calidad

Se utilizó Kather-texture-2016 [1], en la copia publicada en Hugging Face bajo licencia CC BY 4.0. Contiene 5000 parches RGB de 150×150 píxeles, repartidos en ocho clases con exactamente 625 imágenes cada una: Adiposo, Complejo, Detritos, Fondo vacío, Linfocitos, Mucosa, Estroma y Tumor (Fig. 1). Al estar perfectamente balanceado, no fue necesario aplicar pesos de clase ni sobremuestreo.

Antes de modelar se auditó el conjunto completo. No se hallaron archivos corruptos, la resolución y el número de canales fueron homogéneos, y la comparación por hash MD5 no detectó duplicados exactos. Tampoco aparecieron imágenes atípicas por oscuridad, exceso de brillo o desenfoque según el criterio del rango intercuartílico. En consecuencia, el conjunto de trabajo conservó las 5000 imágenes originales.

III-B. Partición y preprocesamiento

Los datos se dividieron de forma estratificada en 3500 imágenes para entrenamiento, 750 para validación y 750 para prueba (70/15/15 %), con la semilla 42. La estratificación se hizo por parche: el conjunto no incluye identificadores confiables de lámina o de paciente, de modo que no es posible garantizar independencia entre particiones a ese nivel. Lo que sí se verificó, mediante MD5, es que ningún archivo idéntico aparece en dos particiones distintas.

La normalización ($x/255$) forma parte del propio modelo. El aumento de datos se aplica únicamente durante el entrenamiento y consiste en volteos horizontales y verticales, rotaciones de hasta $\pm 90°$, zoom de hasta el 10 % y variaciones del 10 % en brillo y contraste, todas ellas transformaciones plausibles en una lámina histológica. Las tuberías de datos se construyeron con `tf.data`.

III-C. Arquitecturas evaluadas

Se compararon tres CNN, resumidas en la Fig. 2.

CNN Baseline. Tres bloques Conv3×3–BatchNorm–ReLU–MaxPool con 32, 64 y 128 filtros, seguidos de agrupamiento global promedio, una capa densa de 256 unidades con Dropout de 0.5 y una salida softmax de ocho clases. Tiene 129 224 parámetros y no incluye conexiones residuales.

CNN Mejorada. Un bloque inicial Conv3×3 de 32 filtros seguido de cuatro bloques residuales (32, 64, 128 y 256 filtros, con *stride* 2 a partir del segundo) y la misma cabeza clasificadora del modelo base. Cada bloque suma su entrada a la salida de dos convoluciones 3×3; cuando cambian las dimensiones, el atajo se proyecta con una convolución 1×1. Reúne 1 297 128 parámetros.

CNN Optimizada. Parte de la misma idea residual, pero añade cuatro decisiones: el aumento de datos se integra dentro del grafo (activo solo en entrenamiento); un *stem* agresivo (Conv5×5 con *stride* 2 y MaxPool 3×3) reduce la resolución de 150 a 38 píxeles desde el inicio; se aplica regularización L2 (10^{-4}) a todas las capas con pesos; y se usa Dropout escalonado, tanto espacial (0.10 y 0.15 entre bloques) como en la cabeza (0.3 y 0.5). Cuenta con cuatro bloques residuales (64, 128, 256 y 256 filtros) y 2 461 672 parámetros.

III-D. Configuración de entrenamiento

Los tres modelos se entrenaron con idéntica configuración: optimizador Adam con tasa de aprendizaje inicial de 10^{-3} y decaimiento de pesos de 10^{-4} [7], entropía cruzada categórica con suavizado de etiquetas de 0.1, lotes de 32 imágenes y un máximo de 50 épocas. Se emplearon parada temprana con paciencia de 10 épocas, reducción de la tasa de aprendizaje a la mitad tras 5 épocas sin mejora (mínimo 10^{-6}) y *checkpoint* sobre la pérdida de validación. La implementación usa TensorFlow 2.21.0 con Python 3.13 y semilla 42, sobre una GPU NVIDIA T4 en Google Colab.

III-E. Protocolo de selección y métricas

Antes de mirar el conjunto de prueba se fijaron los criterios de elección: entre los modelos que cumplieran los límites de tamaño (< 50 MB, medido sobre el archivo `.keras` sin optimizador) y de latencia (< 100 ms por imagen en CPU, calculada como la mediana de 15 inferencias de un parche tras 3 de calentamiento), se elegía el de mayor Macro F1 de validación. El conjunto de prueba se utilizó solo para informar resultados.

Se reportan exactitud, Macro F1, Macro AUC con esquema uno-contra-resto, métricas por clase y matriz de confusión. El intervalo de confianza del Macro F1 se obtuvo con 1000 remuestreos bootstrap de los parches de prueba, y la calibración se resumió con el error de calibración esperado (ECE) [8] calculado con diez intervalos. Como referencia, un clasificador aleatorio uniforme alcanza 12.5 % de exactitud.

IV. Resultados

IV-A. Comparación entre arquitecturas

La Tabla I reúne las métricas de los tres modelos. Los tres superan ampliamente el azar y ofrecen una discriminación muy

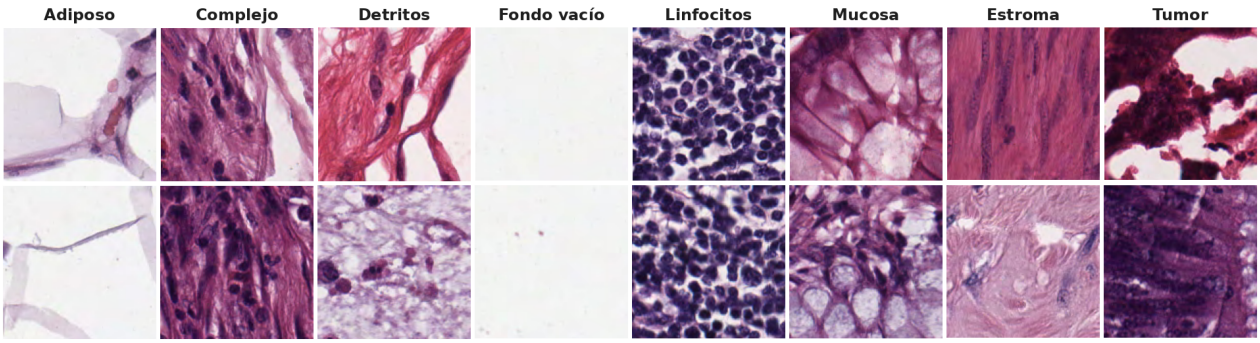


Fig. 1. Parches representativos de cada tipo de tejido (dos ejemplos por clase) extraídos del conjunto Kather-texture-2016.

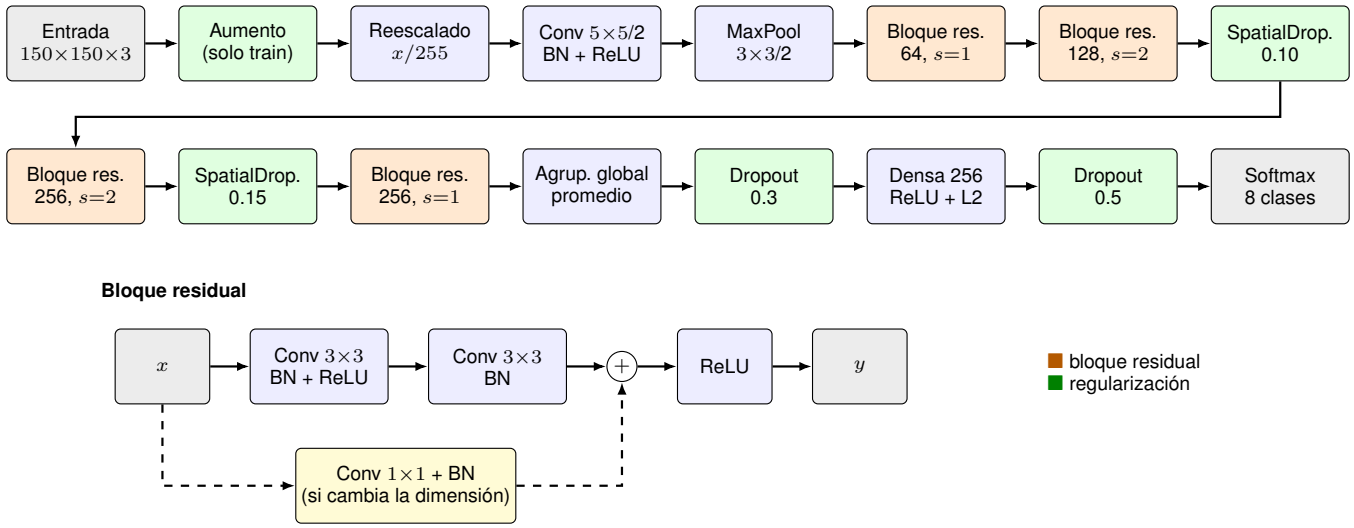


Fig. 2. Arquitectura de la CNN Optimizada (arriba) y detalle del bloque residual (abajo). La CNN Mejorada comparte el bloque residual, pero omite el aumento integrado, el *stem* agresivo, la regularización L2 y los Dropout espaciales; la CNN Baseline carece de atajos.

alta entre clases (Macro AUC ≥ 0.994 en prueba). Las diferencias aparecen en la exactitud y en el costo computacional. La CNN Mejorada obtuvo los mejores valores de validación (Macro F1 de 0.9384) y de prueba (0.9301), pero su latencia en CPU, de 110.4 ms, excede el límite de 100 ms establecido de antemano. La CNN Baseline es la más ligera (0.13 M de parámetros, 1.55 MB y 33.5 ms), aunque con el menor Macro F1 de validación (0.8981). La CNN Optimizada cumple ambas restricciones (28.35 MB y 74.0 ms) y supera al modelo base en validación, por lo que resultó la finalista bajo el protocolo declarado.

La Fig. 3 ilustra la relación entre complejidad y rendimiento en validación. Conviene destacar que más parámetros no equivalen a mejor desempeño: la CNN Mejorada, con aproximadamente la mitad de parámetros que la Optimizada, la supera en Macro F1. Una lectura prudente es que, en este conjunto pequeño, la regularización adicional de la Optimizada no se tradujo en ganancia de exactitud, aunque sí dejó un modelo más rápido que la variante residual simple.

IV-B. Comportamiento durante el entrenamiento

La Fig. 4 muestra las curvas de la CNN Optimizada. La pérdida de validación es muy inestable durante las primeras épocas, con un pico cercano a 5.3 en la quinta, algo esperable con el aumento de datos integrado y una tasa de aprendizaje inicial alta. Tras las reducciones sucesivas de la tasa de aprendizaje (de 10^{-3} a 1.25×10^{-4}) la validación se aproxima a la curva de entrenamiento. La mejor época, según la pérdida de validación, fue la 30, y el entrenamiento se detuvo en la 40 por el criterio de parada temprana. La oscilación residual de la exactitud de validación indica que el modelo no está plenamente estabilizado, y es una de las razones por las que interpretamos con cautela las diferencias pequeñas entre modelos.

IV-C. Desempeño del modelo finalista

En el conjunto de prueba, la CNN Optimizada clasificó correctamente 692 de 750 parches. Su Macro F1 fue de 0.9227, con un intervalo de confianza del 95 % por bootstrap de 0.9015 a 0.9405, y su Macro AUC de 0.9948. La Tabla II detalla el desempeño por clase. Las clases más fáciles son Fondo vacío

Tabla I

COMPARACIÓN DE LAS TRES ARQUITECTURAS. VALID.: CONJUNTO DE VALIDACIÓN; PRUEBA: CONJUNTO DE PRUEBA (750 PARCHES). LA LATENCIA CORRESPONDE A LA CPU DE GOOGLE COLAB. LA FILA RESALTADA ES EL MODELO FINALISTA.

	Parám.	Tamaño	Latencia		Macro F1	Prueba		
Modelo	(M)	(MB)	(ms/img)	Épocas	valid.	Exactitud	Macro F1	Macro AUC
CNN Baseline	0.13	1.55	33.5	47	0.8981	0.9107	0.9110	0.9948
CNN Mejorada	1.30	15.00	110.4	50	0.9384	0.9293	0.9301	0.9956
CNN Optimizada	2.46	28.35	74.0	40	0.9065	0.9227	0.9227	0.9948

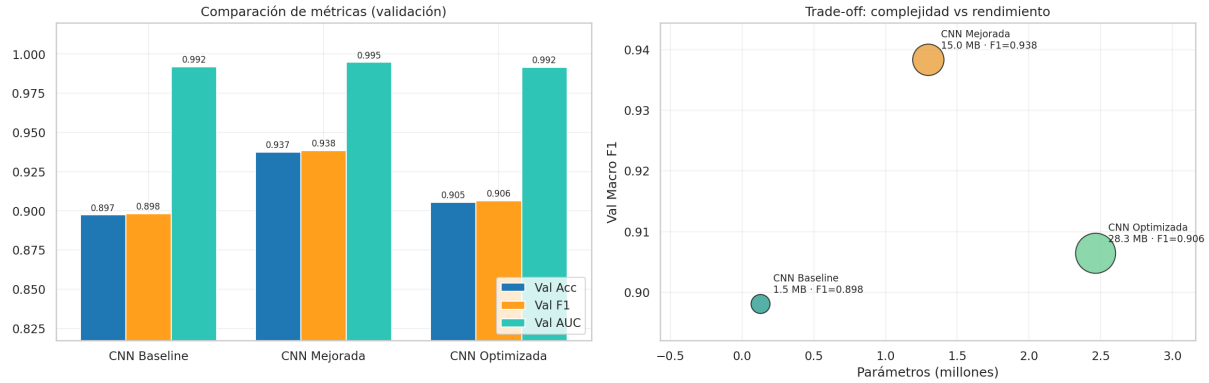


Fig. 3. Izquierda: exactitud, Macro F1 y Macro AUC en validación de las tres CNN. Derecha: relación entre número de parámetros y Macro F1 de validación (el tamaño de cada burbuja es proporcional al tamaño del archivo del modelo).

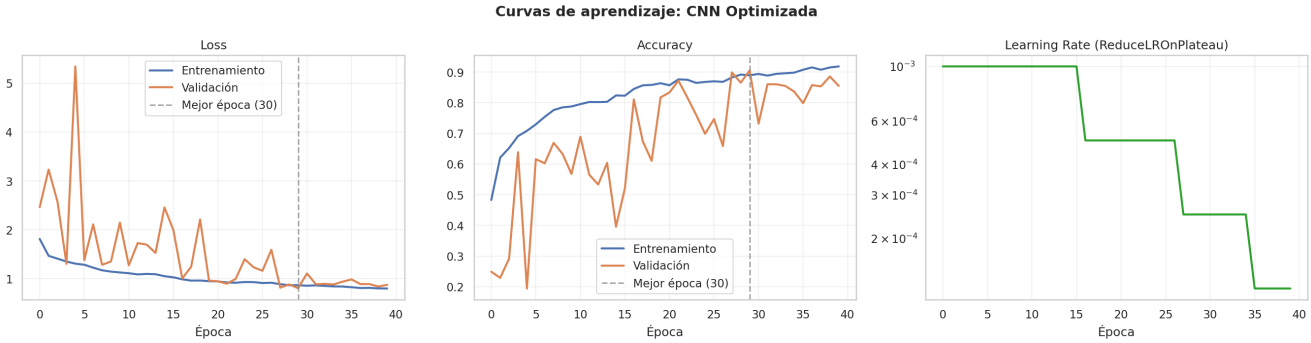


Fig. 4. Curvas de aprendizaje de la CNN Optimizada: pérdida, exactitud y tasa de aprendizaje por época. La línea punteada marca la mejor época según la pérdida de validación.

(F1 de 0.9684) y Tumor (0.9630), mientras que Complejo (0.8432) y Estroma (0.8796) son las más difíciles.

La matriz de confusión (Fig. 5) confirma ese patrón. De los 58 errores (7.73 % del total), los más frecuentes son Complejo clasificado como Estroma (9 casos, 9.7 % de la clase), Linfocitos como Complejo (6 casos, 6.4 %) y Estroma como Complejo (5 casos, 5.3 %). Es razonable pensar que la clase Complejo, que corresponde a estroma complejo con células tumorales aisladas o inmunitarias, comparta rasgos de textura con el estroma; esto es, no obstante, una hipótesis de trabajo, pues el análisis no demuestra causalidad. Las curvas ROC por clase (Fig. 6) muestran, por su parte, una separación muy buena en todas las categorías.

IV-D. Confianza y calibración

La confianza media del modelo (probabilidad máxima del softmax) fue de 0.855 en las predicciones correctas y de 0.590 en las incorrectas (Fig. 7), lo que sugiere que la propia confianza ofrece una señal útil para marcar casos dudosos. Aun así, el 13.8 % de los errores se cometió con una confianza igual o superior a 0.80, y el ECE fue de 0.0914, de modo que la calibración dista de ser perfecta. Conviene recordar que el suavizado de etiquetas puede moderar la confianza sin garantizar, por sí solo, una buena calibración [8]. Por último, el brillo medio de los parches mal clasificados (138.7) fue similar al de los acertados (145.0), por lo que no observamos una asociación clara entre errores e iluminación, aunque este análisis exploratorio no descarta otros sesgos.

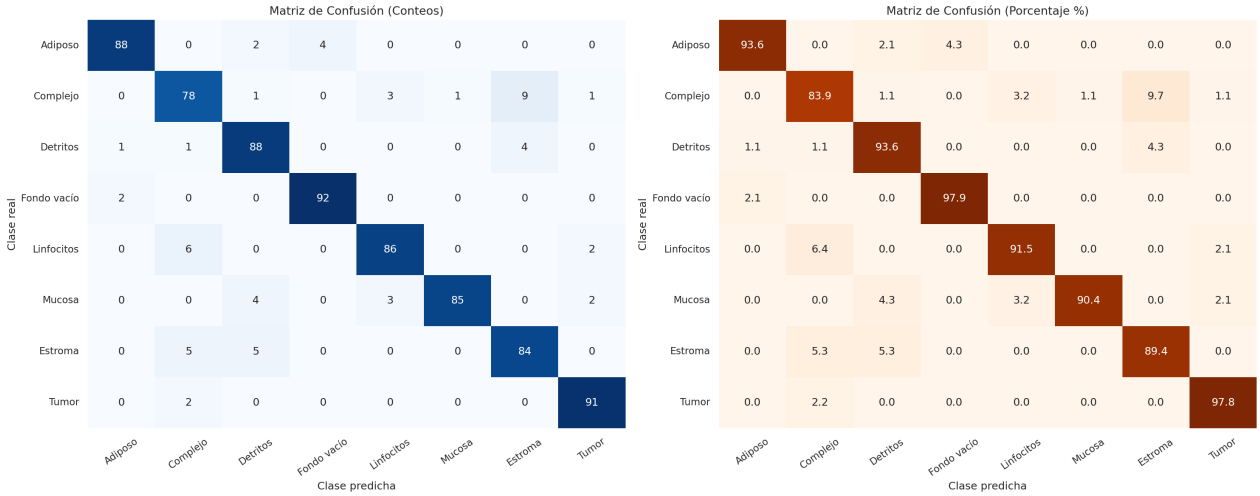


Fig. 5. Matriz de confusión de la CNN Optimizada en el conjunto de prueba: conteos (izquierda) y porcentaje por clase real (derecha).

Tabla II
MÉTRICAS POR CLASE DE LA CNN OPTIMIZADA EN EL CONJUNTO DE PRUEBA.

Clase	Precisión	Sensibilidad	F1	Soporte
Adiposo	0.9670	0.9362	0.9514	94
Complejo	0.8478	0.8387	0.8432	93
Detritos	0.8800	0.9362	0.9072	94
Fondo vacío	0.9583	0.9787	0.9684	94
Linfocitos	0.9348	0.9149	0.9247	94
Mucosa	0.9884	0.9043	0.9444	94
Estroma	0.8660	0.8936	0.8796	94
Tumor	0.9479	0.9785	0.9630	93
Exactitud				0.9227
Promedio macro	0.9238	0.9226	0.9227	750

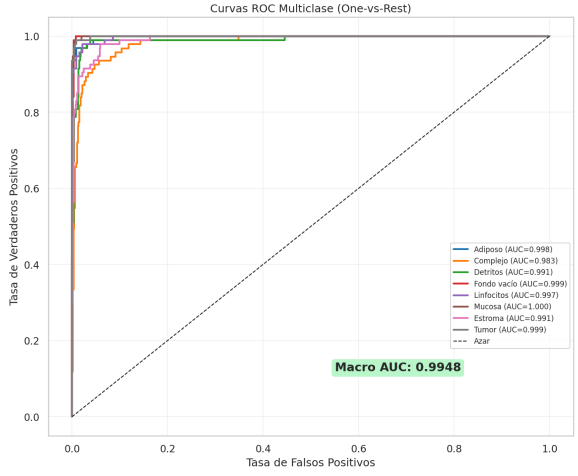


Fig. 6. Curvas ROC uno-contra-resto de la CNN Optimizada en el conjunto de prueba (Macro AUC = 0.9948).

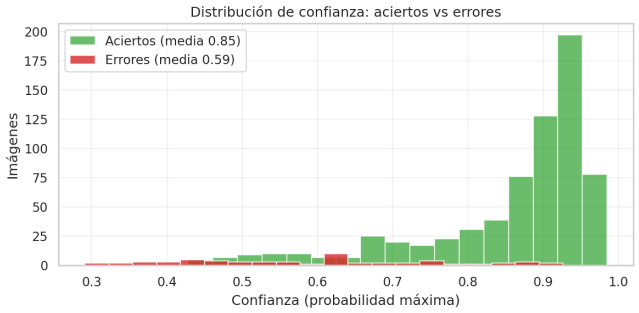


Fig. 7. Distribución de la confianza del modelo en aciertos y errores del conjunto de prueba.

V. DISCUSIÓN

Precisión frente a costo. El resultado más llamativo es que la variante residual más simple obtuvo la mejor exactitud, y que la arquitectura que incorpora más técnicas de regularización quedó ligeramente por debajo. Esto no invalida dichas técnicas, pero sí recuerda que su beneficio depende del tamaño del conjunto y del régimen de entrenamiento. Con 3500 imágenes de entrenamiento, el riesgo de sobreajuste es moderado y la regularización fuerte puede llegar a limitar la capacidad del modelo. Respecto al baseline, los bloques residuales aportaron mejoras de entre 1.2 y 1.9 puntos porcentuales de Macro F1 en prueba, a cambio de un mayor número de parámetros y tiempo de inferencia.

Selección bajo restricciones. La elección de la CNN Optimizada es consecuencia directa del protocolo fijado de antemano, no de su exactitud en prueba. Si el único criterio hubiera sido el Macro F1, se habría escogido la CNN Mejorada. Preferimos declarar esta tensión de forma abierta: en un escenario con otros límites de latencia, la decisión cambiaría. Como indicio de la viabilidad de despliegue, la conversión del finalista a TensorFlow Lite con cuantización *float16* produjo un archivo de 4.70 MB que coincidió al 100 % con el modelo original en una muestra de 200 imágenes, con una latencia media de 15.9 ms por imagen en la CPU de Colab.

Amenazas a la validez. Primero, la partición es estratificada

por parche y no por paciente o lámina. Como el conjunto proviene de un número reducido de muestras tumorales, parches de un mismo paciente pueden aparecer en entrenamiento y en prueba, lo que tiende a sobrestimar la capacidad de generalización a pacientes nuevos. Por la misma razón, el intervalo bootstrap, que supone parches independientes, probablemente subestima la incertidumbre real. Segundo, los tiempos de latencia se midieron en la CPU de Colab y no equivalen a los de un teléfono o un equipo de laboratorio. Tercero, el entrenamiento se ejecutó con una sola semilla, de manera que no estimamos la variabilidad entre repeticiones y las diferencias de pocas décimas entre modelos deben leerse con cautela. Cuarto, los tiempos de entrenamiento no son comparables entre sí con rigor (6.0 min para la Optimizada frente a 19.3 y 26.9 min para los otros), pues el notebook no controla las condiciones de ejecución en la plataforma.

Alcance. El sistema clasifica el tipo de tejido de un recorte; no diagnostica cáncer, no emite pronóstico ni sustituye al patólogo. Se trata de un prototipo académico que no ha sido validado clínicamente.

VI. Conclusiones y trabajo futuro

Se compararon tres CNN sobre Kather-texture-2016 con un protocolo de selección que mantuvo el conjunto de prueba aislado de las decisiones de diseño. La CNN Optimizada resultó finalista al cumplir los límites de tamaño y de latencia, con una exactitud de 0.9227, un Macro F1 de 0.9227 y un Macro AUC de 0.9948 en prueba, valores que superan la meta de Macro F1 de 0.90 que el grupo se había propuesto. La CNN Mejorada fue la más precisa en bruto (Macro F1 de 0.9301), a costa de una latencia que excede el presupuesto fijado, y la CNN Baseline mostró que una red muy compacta ya alcanza un 91 % de exactitud. Los errores se concentran en las clases Complejo y Estroma, y la calibración del modelo es mejorable.

Como líneas de trabajo futuro, consideramos prioritarias: (i) evaluar con particiones independientes por lámina o paciente, usando identificadores confiables; (ii) validar el modelo en datos externos de otros centros; (iii) repetir los experimentos con varias semillas para cuantificar la variabilidad; (iv) incorporar técnicas de calibración; y (v) contrastar estas redes con modelos preentrenados mediante aprendizaje por transferencia.

Disponibilidad de datos y código

El conjunto de datos es público (Kather-texture-2016, licencia CC BY 4.0). El notebook de Colab, las configuraciones, los registros de entrenamiento y los modelos exportados se conservaron junto con sumas de verificación SHA-256 para garantizar la trazabilidad de cada experimento.

Referencias

[1] J. N. Kather *et al.*, "Multi-class texture analysis in colorectal cancer histology," *Scientific Reports*, vol. 6, art. no. 27988, 2016, doi: 10.1038/srep27988.

[2] G. Litjens *et al.*, "A survey on deep learning in medical image analysis," *Medical Image Analysis*, vol. 42, pp. 60–88, 2017.

[3] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.

[4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 770–778.

[5] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2015, pp. 448–456.

[6] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *J. Mach. Learn. Res.*, vol. 15, pp. 1929–1958, 2014.

[7] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2015.

[8] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2017, pp. 1321–1330.